CERTAN

Basis Pengetahuan Korpus dan Vector Semantic Search

TUGAS 03 / MILESTONE 3

10S3001 - Kecerdasan Buatan (+P)
Program Studi Sarjana Sistem Informasi
Institut Teknologi Del | Semester Gasal 2026/2027

DRAFT UNTUK REVIEW TIM - KODE KELOMPOK BELUM DIISI

Rony Reynaldy Pangaribuan
Doydenggan Simanjuntak
Indah Nainggolan

Tanggal penyusunan: 6 November 2026
Dosen pengampu: Samuel Indra Gunawan Situmeang

Sumber	Korpus aktif	Representasi	Penyimpanan
15 dokumen	503 chunk	384 dimensi	ChromaDB persisten

Ringkasan

CERTAN menyediakan rujukan untuk diagnosis jaringan, pengelolaan insiden dan kebijakan jaringan kampus. Pipeline membaca teks yang telah direview, melakukan normalisasi dan recursive word-aware chunking, membentuk embedding multilingual, lalu mengambil dokumen berdasarkan cosine similarity.

Pada 15 kueri utama, Recall@3 tercatat 0,8750 dan MRR 0,8500. Ketiga OOD sederhana ditolak pada ambang diagnostik 0,50. Challenge set yang lebih sulit tetap menunjukkan false acceptance, sehingga threshold tidak diadopsi sebagai kebijakan default.

Laporan ini memisahkan hasil penelitian lama yang dibekukan dari regresi setelah perubahan splitter. Sistem merupakan prototipe akademik dan belum menyediakan jawaban LLM, pengesahan SOP lokal, atau keputusan operasional otomatis.

01 Korpus dan sumber

Korpus terdiri dari delapan sumber diagnosis jaringan, empat sumber proses insiden/keamanan dan tiga sumber kebijakan. Sebanyak 13 dokumen berbahasa Inggris dan dua Indonesia. Semua PDF asli dan teks hasil review dipertahankan identik terhadap snapshot sebelum cleanup.

ID	Dokumen	Publisher
DOC01	Wireless technology troubleshooting guidance	Microsoft Learn
DOC02	DNS troubleshooting guidance	Microsoft Learn
DOC03	DHCP troubleshooting guidance	Microsoft Learn
DOC04	Troubleshoot problems on the DHCP client	Microsoft Learn
DOC05	TCP/IP communication troubleshooting guidance	Microsoft Learn
DOC06	Open vSwitch VLAN Troubleshooting FAQ	Open vSwitch Project
DOC07	Diagnose packet loss	Microsoft Learn
DOC08	Advanced troubleshooting 802.1X authentication	Microsoft Learn
DOC09	OPS-01 Service desk, eskalasi, dan komunikasi ke pengguna	DTSI Universitas Harapan Bangsa
DOC10	INC-02 Insiden gangguan layanan TI (operasional)	DTSI Universitas Harapan Bangsa
DOC11	UCF IT Incident Management Policy & Procedure	University of Central Florida Information Technology
DOC12	Procedure P4-004N: IT Security Incident Management	The University of Utah
DOC13	University Network Administration, Policy 08-010	Oregon State University
DOC14	Network Acceptable Use Policy	Western Michigan University
DOC15	Network Management	Indiana University Bloomington

13 teks berasal dari HTML resmi karena PDF tidak menyediakan ekstraksi memadai. DOC11 dan DOC13 memakai teks PDF native. Snapshot TXT memungkinkan pembangunan ulang offline tanpa mengambil ulang halaman yang mungkin telah berubah.

DOC09/10 tetap DRAFT. DOC11 memiliki keterbatasan tabel/diagram. Sumber universitas lain adalah referensi topikal, bukan SOP resmi IT Del. URL, hak penggunaan, hash dan catatan review lengkap ada pada data/corpus/final/manifest.json.

02 Ingestion, cleaning dan chunking

Alur implementasi

```
PDF/HTML resmi -> ekstraksi kandidat -> review -> TXT final -> normalisasi -> recursive chunking -> embedding
-> ChromaDB -> semantic retrieval.
```

Ekstraksi lokal tersedia melalui corpus.prepare untuk PDF, HTML dan teks. Output baru dibuat tanpa overwrite. Hasil kosong, halaman tanpa teks dan HTML challenge ditolak. Adopsi kandidat ke korpus memerlukan review; rebuild rutin menggunakan 15 TXT terverifikasi yang tersedia.

Pembersihan dan keterlacakan

Normalisasi menyamakan newline dan Unicode, membuang karakter tak terlihat dan merapikan whitespace. Heading, langkah, perintah serta urutan kata substantif dijaga. Koreksi layout spesifik sumber mengikuti hasil review historis; isi tabel atau diagram tidak dikarang.

Strategi rekursif

Dokumen dibagi menurut heading/pertanyaan, kemudian bagian pendek dikelompokkan. Jendela kata dibatasi tokenizer. Pemilihan batas memanggil fallback rekursif dari paragraf ke baris, kalimat, kemudian kata. Batas struktur harus mengisi lebih dari setengah jendela untuk menghindari fragmen sangat pendek. Overlap dimulai ulang pada kelompok bagian baru.

Parameter	Konfigurasi aktif
Batas token	96 termasuk special tokens; batas model 128
Overlap	Diminta 10 kata; dibatasi anggaran token dan kemajuan chunk
Batas sekunder	250 kata sebelum pengukuran tokenizer
Hasil aktual	503 chunk; minimum 19, median 81, maksimum 96 token
Integritas	Urutan kata tercakup; tidak ada chunk di atas batas model

Justifikasi dan sensitivitas

Profil	Chunk	Median token	Maksimum
96 / overlap 10 kata	503	81	96
96 / tanpa overlap	422	81	96
120 / overlap 12 kata	387	104	120

96 token memberi margin 32 token terhadap model. Overlap menambah sekitar 19,2% chunk dibanding tanpa overlap, dengan manfaat menjaga konteks batas. Profil 120/12 memberi chunk lebih sedikit tetapi margin hanya delapan token. Sensitivitas ini mengukur struktur/biaya; tidak membuktikan optimum akurasi universal.

03 Embedding dan vector store

Model dan representasi

Sentence-Transformers paraphrase-multilingual-MiniLM-L12-v2 dipakai untuk kueri Indonesia dan mayoritas sumber Inggris. Vektor float32 berdimensi 384 dinormalisasi L2. Model dimuat lazy dan digunakan kembali dalam proses yang sama. Dokumen dan kueri wajib memakai model yang sama.

Pilihan multilingual sesuai konteks bilingual dan skala prototipe. Laporan ini tidak mengklaim model terbaik atau hasil pembandingan lintas keluarga embedding.

Pemisahan modul

Modul	Tanggung jawab
corpus/prepare.py dan cleaning.py	Ekstraksi lokal dan normalisasi
corpus/chunking.py dan ingestion.py	Pembatasan token, struktur rekursif, overlap dan cakupan sumber
knowledge/embeddings.py	Encoder dokumen/kueri dan normalisasi vektor
knowledge/vector_store.py	PersistentClient, upsert, query dan pengelolaan koneksi
knowledge/retrieval.py	Indexing, cosine dan agregasi dokumen
knowledge/final_cli.py	Build, verify, index dan search resmi

Metadata dan persistensi

Metadata memuat document_id, sumber, judul, bagian, chunk_index, bahasa, publisher, jenis dokumen, URL, metode ekstraksi, hash PDF/TXT, path TXT aktif, versi/profil, review note dan status/hak sumber. Sebanyak 127 chunk memiliki pemetaan halaman exact dan unik pada PDF native; sumber HTML tidak diberi halaman perkiraan.

ChromaDB memakai collection certan_knowledge, explicit embeddings, HNSW cosine dan penyimpanan .local/chroma-final-recursive/. Telemetry dinonaktifkan. Upsert ID yang sama tidak menambah duplikat. CLI menolak indeks stale/campuran sebelum encoding dan memverifikasi ID, teks, metadata, dimensi serta norma vektor.

Persistensi diuji melalui pembukaan ulang klien serta proses terpisah. Metadata disiapkan untuk filtering/hybrid search pada pengembangan selanjutnya; ranking aktif menggunakan dense cosine.

04 Benchmark retrieval

Benchmark utama memenuhi cakupan modul melalui 15 kueri: delapan relevan, dua parafrasa/sinonim, dua ambigu dan tiga OOD. Label ditetapkan dari sumber dan mencantumkan document_id target serta alasan. Kueri ambigu dapat memiliki beberapa dokumen relevan.

Ranking dokumen memakai cosine tertinggi per document_id dari 100 kandidat chunk. P@k dan R@k dirata-ratakan pada kueri positif; MRR terbatas kandidat yang terambil. OOD tidak memiliki recall atau MRR yang terdefinisi. Similarity bukan probabilitas.

Split	Kueri	P@1	R@3	R@5	MRR
Legacy 15	15	0.7500	0.8750	0.9583	0.8500
Development	36	0.8333	0.9444	1.0000	0.9028
Validation	36	0.8333	1.0000	1.0000	0.8889
Final_test lama (regresi)	48	0.7083	0.9583	0.9583	0.8333
Final_test v3 (beku)	48	0.7083	0.9167	0.9583	0.8122

Semua split live sudah pernah terlihat. Angka baru merupakan regresi setelah splitter berubah, bukan holdout independen baru. Hasil v3 asli, label dan observasi dipertahankan identik byte. Perbedaan final_test bersifat deskriptif tanpa klaim signifikansi.

Rancangan kueri demonstrasi

ID kueri	Kategori	Target
wifi_diagnosis	relevant	DOC01
wifi_paraphrase	paraphrase	DOC01
dns	relevant	DOC02
dhcp	relevant	DOC03, DOC04
vlan	relevant	DOC06
packet_loss	paraphrase	DOC07
authentication	relevant	DOC08, DOC01
escalation	relevant	DOC09, DOC10
incident_ambiguous	ambiguous	DOC09, DOC10, DOC11
security	relevant	DOC12
wifi_policy	ambiguous	DOC13
acceptable_use	relevant	DOC14
ood_cafeteria	out_of_domain	Tidak ada
ood_weather	out_of_domain	Tidak ada
ood_tuition	out_of_domain	Tidak ada

05 OOD dan analisis kegagalan

Kalibrasi menggunakan development saja, grid 0-1 langkah 0,05. Kriterianya meminimalkan FAR dengan maksimal satu positif ditolak; seri dipilih menurut FRR lalu threshold lebih rendah. Ambang yang terpilih adalah 0,55. Validation dan final_test tidak memilih ulang threshold. Ambang ini belum menjadi kebijakan default.

Split	Ambang	FA/OOD	FR/positif	Presisi tolak	OOD ditolak
legacy	0.50	0/3	0/12	1.0000	1.0000
development	0.55	6/18	0/18	1.0000	0.6667
validation	0.55	3/18	0/18	1.0000	0.8333
final_test	0.50	18/24	1/24	0.8571	0.2500
final_test	0.55	9/24	2/24	0.8824	0.6250

FAR = OOD diterima / seluruh OOD. FRR = positif ditolak / seluruh positif. Precision penolakan = OOD ditolak / semua kueri ditolak; tidak terdefinisi bila tidak ada penolakan. Precision perlu dibaca bersama cakupan penolakan OOD dan FRR.

Kesalahan yang masih terlihat

- WiFi diagnosis masih menempatkan DOC13 kebijakan di atas DOC01 diagnosis; target DOC01 berada pada rank 5 pada kueri legacy.

- Kueri packet loss menempatkan DOC03 DHCP di atas DOC07; istilah diagnosis klien/jaringan beririsan.

- Kueri acceptable use menempatkan DOC13 di atas DOC14 karena kedekatan topik kebijakan.

- Pada challenge final_test, threshold 0,55 masih menerima 9 dari 24 OOD dan menolak 2 dari 24 positif.

Tiga OOD sederhana yang berhasil ditolak tidak membuktikan generalisasi. Kandidat guard dan reranking judul sebelumnya ditolak; keputusan dan hasil negatifnya tetap disimpan. Perbaikan lanjutan membutuhkan penilaian tim/pakar serta kueri baru yang belum dipakai untuk desain.

Korpus bukan SOP resmi lokal, DOC09/10 masih DRAFT, tabel/diagram DOC11 terbatas dan label belum divalidasi manusia independen. Tidak ada klaim kesiapan produksi atau seluruh deskriptor nilai 100 terpenuhi.

06 Repository minimal dan verifikasi

Aspek	Sebelum	Sesudah
File checkout deliverable	265	125
Markdown	34	15
TXT korpus	60	15
Kumpulan chunk aktif/deliverable	10 file lintas versi	1 file final
Dokumentasi M3	14 Markdown	3 Markdown utama
File lama dikeluarkan	-	146

Seluruh file yang dikeluarkan dapat dipulihkan pada tag archive/m3-before-minimal-cleanup-20261106, commit bc0c4c1a49d977236378c73e26794332b2056c54. Tag menyimpan versi korpus, generator label, eksperimen, laporan dan tes historis. Snapshot bersifat lokal sampai tag dikirim ke remote.

Hasil pemeriksaan

- Tes sebelum refaktor: 228 lulus dan 3 skipped. Tes aktif sesudah cleanup: 167 lulus, termasuk model asli. Selisih jumlah mencakup tes penelitian yang diarsipkan, bukan ukuran peningkatan coverage.

- 15 PDF dan 15 TXT final cocok byte terhadap snapshot arsip. Kode sumber M1/M2 dipertahankan identik.

- Korpus 503 chunk dibangun ulang deterministik; seluruh urutan kata tercakup dan tidak ada chunk di atas 96 token.

- 503 vektor berdimensi 384 dan bernorma satu terverifikasi pada indeks persisten; buka ulang proses terpisah tercakup tes.

- Checksum bukti penelitian dan replay metrik baseline lulus. Lockfile dependency diperiksa dengan uv lock --check --offline.

Pemetaan terhadap rubrik resmi

Bobot	Komponen	Bukti
25%	Korpus dan preprocessing	Sumber, provenance, cleaning, splitter rekursif, overlap dan sensitivitas
45%	Embedding dan ChromaDB	Encoder multilingual, metadata, modul terpisah dan persistensi
30%	Retrieval dan analisis	Relevan/sinonim/ambigu/OOD, cosine, metrik dan analisis kegagalan

07 Reproduksi dan referensi

Jalankan dari root repository

```
uv sync --locked
uv run --locked python -m proyek_certan.knowledge.final_cli verify
uv run --locked python -m proyek_certan.knowledge.final_cli build
uv run --locked python -m proyek_certan.knowledge.final_cli index
uv run --locked python -m proyek_certan.knowledge.final_cli verify --index
uv run --locked python evaluation/benchmarks/final_pipeline.py --live
uv run --locked python -m pytest -q
```

Python 3.11+ diperlukan. Model pertama memerlukan unduhan; cache model tersimpan di .cache/models/. Database dan cache tidak di-commit. Database persisten benar-benar dibangun dan diuji; build ulang menggunakan korpus final. Tes model asli diaktifkan melalui CERTAN_RUN_MODEL_TESTS=1.

Dokumen dan bukti repository

- README.md: instalasi dan pintu masuk seluruh milestone.

- docs/milestone-3/README.md: urutan demonstrasi dan CLI resmi.

- docs/milestone-3/pipeline.md: sumber, preprocessing, embedding dan penyimpanan.

- docs/milestone-3/evaluation.md: hasil retrieval, OOD dan batas klaim.

- data/corpus/final/manifest.json: daftar lengkap sumber, URL, hak/status, konfigurasi dan hash.

- evaluation/results/final.json: hasil live, ranking per kueri, kalibrasi dan sensitivitas.

- evaluation/evidence.json: checksum bukti beku, inventaris cleanup dan verifikasi.

- evaluation/quality-v3/: label, observasi, hasil asli dan keputusan penelitian terpilih.

Referensi utama

1. Institut Teknologi Del. Tugas 3 - Milestone 3: Pembangunan Basis Pengetahuan Korpus & Vector Semantic Search. 10S3001 Kecerdasan Buatan (+P), 14 Oktober 2026, halaman 1-3.

2. Manifest sumber CERTAN: 15 dokumen dari Microsoft Learn, Open vSwitch, DTSI Universitas Harapan Bangsa, UCF, University of Utah, Oregon State University, Western Michigan University, dan Indiana University Bloomington. URL serta status masing-masing sumber tercatat pada manifest, bukan dinyatakan sebagai SOP lokal.

3. Repository proyek: https://github.com/RonyPangaribuan/Proyek-Certan. Dependency Python dikunci pada uv.lock; lisensi kode MIT, hak sumber korpus mengikuti masing-masing publisher.

Sebelum pengumpulan

Isi kode kelompok, review isi oleh anggota tim dan sesuaikan nama menjadi Grup{KodeKelompok}-Tugas03.pdf. Lengkapi tautan GitHub yang memuat implementasi serta tag arsip. Draft ini telah berisi hasil yang diuji, tetapi tidak mengesahkan SOP atau menjamin nilai tertentu.